

<주제>

와인 품질 분류

<코드 흐름>

1. 데이터 로드 및 데이터 형태&결측치 유무 확인
2. EDA
 - 타깃 분석: sns.countplot -> 데이터 불균형 확인
 - 상관관계 분석: 눈.heatma
3. 전처리
 - 인코딩
 - 스케일링
4. 모델 학습 및 튜닝
 - RandomForestClassifier
 - GridSearchCV
 - accuracy_score

<코드>

#인코딩

```
X_features_ohe = pd.get_dummies(X_features)
```

#하이퍼파라미터 최적화+train

```
grid_cv = GridSearchCV(ridge_reg, param_grid=ridge_params,  
scoring='neg_mean_squared_error', cv=5) grid_cv.fit(X_features, y_target)
```

#원래 스케일 복원 및 평가

```
y_test_exp = np.expm1(y_test)
```

```
pred_exp = np.expm1(pred)
```

```
evaluate_regr(y_test_exp, pred_exp)
```

<어려운 점>

클래스 불균형: 와인 품질은 5,6등급에 데이터가 쏠려 있어, 덜 쏠려있는 등급은 분류하기 어려움

<인상깊은 점>

이상치 처리함으로써 모델 성능 크게 향상됨, EDA에서 확인한 알코올 도수 영향력이 실제 모델의 feature_importance_ 수치와 일치함

<배울 점>

log1p같은 전처리나 이상치 제거가 성능 개선에 매우 중요함. 모델링 결과에 따라 최적화 과정을 반복함