

<주제>

- 대출 부도 리스크 예측하기

<변수 설명>

marital_status: 결혼 여부

education_level: 최종 학력 수준

employment_status: 고용형태

annual_income: 연간 소득

debt_to_income_ratio: 총부채원리금상환비율

credit_score: 신용 점수

lian_amount: 신청한 대출 금액

interest_rate: 대출 연 이자율

grade_subgrade: 대출 신용 등급

loan_paid_back: 대출 상환 여부 (타겟 데이터)

<파이프라인>

1. 전처리

- 1) 수치형 변수 처리
- 2) 소수부분 분리해서 모델 특성을 추출하기
- 3) Pairwise interaction을 통해 고차원 범주형 변수 생성하기

2. 인코딩

- 1) OFF 타겟 인코딩
- 2) Frequency encoding

3. 모델링 및 검증

- 1) 5-Fold Stratified Cross Validation
- 2) 하이퍼파라미터 튜닝
- 3) XGBoost Classifier 선정하기

<주요 코드>

- 합성 데이터 패턴 추출

```
df['income_rnd'] = df['annual_income'].round(0)
df['dti_rnd'] = df['debt_to_income_ratio'].round(1)

interaction_pairs = [('grade_subgrade', 'income_rnd'),
                    ('grade_subgrade', 'dti_rnd')]
for col1, col2 in interaction_pairs:
    df[f'{col1}_{col2}'] = df[col1].astype(str) + '_' + df[col2].astype(str)
```

- 데이터 누수 방지 및 인코딩

```
for i, (train_idx, val_idx) in enumerate(skf.split(X, y)):
    X_train, X_val = X.iloc[train_idx], X.iloc[val_idx]

    encoder = TargetEncoder(cols=interact_cols)
    X_train_encoded = encoder.fit_transform(X_train, y.iloc[train_idx])
    X_val_encoded = encoder.transform(X_val)

    model.fit(X_train_encoded, y.iloc[train_idx])
```

<새롭게 알게된 내용>

- 데이터를 ai 모델로 재가공하는 과정에서 소수점 이하의 반올림 경계에 인위적인 패턴인 artifacts가 남는다는 것을 새롭게 알게 되었다. 그리고 이 규칙성을 활용해 피처 엔지니어링을 해봤다.

<어려운 내용>

- 전체 데이터를 기준으로 학습했을 때 검증 데이터의 정보보다 모델에 유출되는 문제가 있어, 이를 해결하는 것이 어려웠다. 이를 해결하기 위해 K-Fold 교차 검증 내에서만 각 fold별로 타겟 인코딩을 수행하는 OOF를 구축하는 부분이 가장 어려웠다.

<배울 점>

하나의 지표가 아니라 대출 등급과 부채 비율의 상관관계를 엮은 pairwise interaction 변수 설계를 한 점이 배울 만하다.