

<주제>

- 영화 관객 수 예측 프로젝트

<파이프라인>

1. 전처리 및 eda

- 데이터 결측치 및 이상치 확인
- 배급사 이름 수정하기(이름 인식 오류 방지 위해 특수문자 제거)

2. 피처 엔지니어링

- num_rank: 배급사 순위 인코딩(관객 수가 가장 많은 배급사가 1등이 되도록)
- genre_rank: 장르 순위 인코딩(장르별 평균 관객 수를 기준으로 순위를 정함)
- screening_rat: 원핫 인코딩으로 변환
- num_actor: 분포의 skewness를 줄이기 위해 매우 수 와 관객수에 np.log1p를 적용해서 정규화하기.

3. 데이터 분할 및 검증 구조 설정하기

- 피처 및 타겟 분리
- K-Fold 교차 검증 구조 설정하기 (n_splits=10)

4. 모델링 및 앙상블 학습

- 여러 회귀 모델 정의 및 각 fold마다 stratified/K-Fold 앙상블 방식 사용/

<주요 코드>

1. 배급사 텍스트 정제 및 순위 인코딩

re.sub로 같은 배급사임에도 텍스트를 다르게 인식하는 문제를 해결하고 평균 관객수 기반으로 랭킹화해서 트리 모델이 학습하기 좋은 형태로 변환하는 전처리 과정임.

```
import re
train['distributor'] = [re.sub(r'\([^)]*\)| \([^)]*\)| \(\주\)|㈜채널', '', x).strip() for x
in train['distributor']]
test['distributor'] = [re.sub(r'\([^)]*\)| \([^)]*\)| \(\주\)|㈜채널', '', x).strip() for x
in test['distributor']]

distributor_rank =
train.groupby('distributor').box_office.mean().reset_index().sort_values(by='box_office',
ascending=False)
distributor_rank['num_rank'] = [i + 1 for i in range(distributor_rank.shape[0])]
```

```
dist_map = distributor_rank.set_index('distributor')['num_rank'].to_dict()
train['num_rank'] = train['distributor'].map(dist_map)
test['num_rank'] = test['distributor'].map(dist_map)
```

2. Skewness(우측으로 꼬리가 매우 긴 분포)를 완화해서 정규분포꼴로 만들어주기 위해 np.log1p 를 적용하기

```
import numpy as np
y = np.log1p(train.box_off_num)
```

3. 10-Fold 교차 검증 및 멀티 모델 앙상블 루프

데이터를 10 개로 나누어 모델을 검증 하고 , 5 개의 트리기반 앙상블 모델(GBM, LightGBM, XGBoost, CatBoost, NGBoost)동시에 훈련하고 평균을 내는 코드

```
from sklearn.model_selection import KFold

from sklearn.ensemble import GradientBoostingRegressor
from lightgbm import LGBMRegressor
from xgboost import XGBRegressor
from catboost import CatBoostRegressor
from ngboost import NGBoostRegressor

kf = KFold(n_splits=10, shuffle=True, random_state=42)

# 초기화
gb_pred = np.zeros((test.shape[0]))
lgbm_pred = np.zeros((test.shape[0]))
xgb_pred = np.zeros((test.shape[0]))
cat_pred = np.zeros((test.shape[0]))
ngb_pred = np.zeros((test.shape[0]))

# 교차 검증 루프 진행
for tr_idx, val_idx in kf.split(X, y):
    tr_x, tr_y = X.iloc[tr_idx], y.iloc[tr_idx]
    val_x, val_y = X.iloc[val_idx], y.iloc[val_idx]

    # 5 개 모델 정의 및 학습
    gbm.fit(tr_x, tr_y)
    lgbm.fit(tr_x, tr_y)

    # 산술평균
    gb_pred += (np.exp1(gbm.predict(target)) / 10)
    lgbm_pred += (np.exp1(lgbm.predict(target)) / 10)
```

<새롭게 배운 점, 인상깊은 점, 어려운 점>

새롭게 배운 점: 순위 인코딩을 통해 배급사나 장르처럼 종류가 많은 범주형 변수를 단순히 원핫 인코딩을 하는 것이 아니라 타겟 변수의 평균을 기준으로 순위를 매겨 수치화 하는 방식을 새로 배웠음.

인상깊은 점: 배급사 데이터에서 re.sub 을 활용해 텍스트 인식에 방해가 되는 것들을 제거한 점이 인상깊었음. 기초적인거라 중요하다는 것을 상기함.

어려운 점: train 과 test 데이터 간의 데이터 불일치를 처리하는 것을 이해하는게

어려웠음 trian 데이터의 평균값으로 num_rank 를 만들었는데, test 데이터에만 존재하는 새로운 배급사는 랭크화되지 않아 결측치가 발생함. 이를 예방하는 과정이 까다롭다고 느껴졌음.