

<주제>

스티커 판매량 예측하기

<코드 파이프라인>

1. 데이터 전처리 및 eda
 - 결측치 확인 및 날짜를 year, month, day, dayofweek으로 변환함.
2. 피쳐 엔지니어링
 - 주말여부를 나타내는 피쳐 is_weekend 생성
3. Train/test 데이터 분리
 - 시간순서를 고려해서 분리함
4. Xgboost 모델 학습
 - 이 과정에서 `log1p()`로 판매량을 로그 변환하여 다시 학습함.
 - `expm1()`으로 다시 원래 판매량 스케일로 복원함
5. MAPE로 성능 평가함
6. 최종 모델로 test 데이터의 판매량 예측

< 주요 코드 >

1. 날짜 데이터 피쳐 엔지니어링

```
data['date'] = pd.to_datetime(data['date'])
data['year'] = data['date'].dt.year
data['month'] = data['date'].dt.month
data['day'] = data['date'].dt.day
data['dayofweek'] = data['date'].dt.dayofweek
data['is_weekend'] = data['dayofweek'].apply(
    lambda x: 1 if x >= 5 else 0
)
```

2. Xgboost 모델 학습 및 로그 변환

```
3. model = XGBRegressor(
4.     n_estimators=1000,
5.     learning_rate=0.05,
6.     max_depth=6,
7.     random_state=42
8. )
9. model.fit(
10.     X_train,
11.     np.log1p(y_train),
12.     eval_set=[(X_val, np.log1p(y_val))],
```

```
13.     verbose=100
14. )
15. log_preds = model.predict(X_val)
    final_preds = np.expm1(log_preds)
```

3. test 데이터와 train 데이터의 피쳐 일치시키기

```
for col in model_columns:
    if col not in test_df.columns:
        test_df[col] = 0
test_df = test_df[model_columns]
log_test_preds = model.predict(test_df)
final_test_preds = np.expm1(log_test_preds)
```

<새롭게 배운 점>

날짜 데이터를 그대로 사용하는 것이 아니라 year, month 등으로 분해하면 모델이 시간에 따른 판매 패턴을 학습하는 데 도움된다는 것을 알게 되었다. 또한 국가별 공휴일 또한 피쳐엔지니어링에 포함된다는 것을 배웠다.

<인상 깊었던 점>

같은 데이터라도 피쳐 엔지니어링이나 데이터 변환 방법에 따라 모델 예측 방식이 달라질 수 있다는 점이 인상깊었다. 왜냐하면 솔루션에서는 xgboost 모델과 로그 변환까지 적용한 모델의 MAPE를 비교하면서 모델 성능을 개선하였는데, 이 점이 인상깊었다.

<어려웠던 점>

가장 어려웠던 점은 시간 순서가 있는 데이터를 랜덤 분할 방식으로 나누지 않고 시간 기반으로 분리하는 것이었는데, 이는 미래 데이터로 과거를 예측하는 상황이 발생하지 않기 위함이었다.