

<대회 주제>

칼로리 소모량을 예측하는 회귀 대회

<파이프라인>

1. Eda

- 결측치, 통계량 확인, calories 타겟 분포를 히스토그램으로 시각화, 상관관계 확인

2. 전처리 및 피처 엔지니어링

- 파생변수 4개 생성함. Sex 칼럼을 LabelEncoder로 인코딩함.

3. Split 및 모델링

- X,y 분리(test_size=0.20), GaussianNB 및 BernoulliNB 두 모델을 준비함. 그러나 BernoulliNB는 실제 예측 및 학습에 사용되지 않음.

<핵심 코드>

1. 도메인 지식을 기반으로 파생 변수들을 생성함

```
train["BMI"] = train["Weight"] / ((train["Height"] / 100) ** 2)
train["Duration_per_Heart"] = train["Duration"] / train["Heart_Rate"]
train["Intensity"] = train["Heart_Rate"] * train["Body_Temp"]
train["Temp_per_Minute"] = train["Body_Temp"] / train["Duration"]
```

2. train에는 fit_transform, test에는 transform만 적용함

```
le = LabelEncoder()
train["Sex"] = le.fit_transform(train["Sex"]) # female=0, male=1
test["Sex"] = le.transform(test["Sex"])
```

3. 수치형 변수간 상관관계를 히트맵으로 시각화함

```
num_cols = train.select_dtypes(include=['int64', 'float64']).columns
sns.heatmap(train[num_cols].corr(), annot=True, cmap="coolwarm",
            fmt=".2f")
```

<새롭게 알게 된 점>

BMI, Duration_per_Heart, Intensity 같은 피처를 만들 때 단순 사칙연산이더라도 도메인 지식을 반영한 피처는 모델 성능에 도움이 크게 된다는 것을 알았음.

<배울 점>

train에는 fit_transform, test에는 transform만 쓰는 인코딩 방식이 데이터 누수 방지를 해줄 수 있어서, 이 점은 배울 법했음.

<어려운 점>

이 대회는 회귀 문제 대회인데, 왜 분류 모델과 지표를 사용하려고 했는지 잘 모르겠음.